

# Relatório da disciplina de Redes Neurais

Vitor Amorim\*, Wesley Pereira Pimentel†  
Universidade Federal do Espírito Santo  
Vitória, Espírito Santo, Brasil  
vitor.amorim@edu.ufes.br, wesley.pereira@edu.ufes.br

**Abstract**—Relatório apresentado na disciplina de Redes Neurais, ministrada pelo professor dr. Thomas Walter Rauber, como forma parcial de avaliação. O presente trabalho tem como finalidade utilizar o método de descida de gradientes para resolução de 4 problemas de minimização.

**Index Terms**—Inteligência Artificial, Otimização, Redes Neurais

## I. INTRODUÇÃO

O Algoritmo Genético (AG), pode ser definido, por [1], como um método computacional de busca baseado em mecanismos de evolução natural e da genética. Em um AG, uma população de possíveis soluções para um dado problema evolui de acordo com operadores probabilísticos concebidos a partir de conceitos biológicos. De modo que há uma tendência dos indivíduos representarem soluções cada vez melhores à medida que o processo avança.

## II. MÉTODO

Foi utilizado o algoritmo genético para resolver os três problemas de otimização descritos. E adotado como parâmetro para o problema do caixeiro viajante e da regressão, o tamanho da população igual a 200 e o número de gerações igual a 1000, e para o do aprendizado de máquina, 100, indivíduos e 250 gerações. O parâmetro de mutação estabelecido foi de 10%. O programa foi implementado em linguagem de programação *Python*, com o compilador *Python 3.8*, num ambiente cuja máquina possuía um processador da Intel Core i5-8250U CPU @ 1.60GHz, Memória RAM de 8GB, no sistema operacional Microsoft Windows.

Executou-se o algoritmo para resolver os problemas 5 vezes com os mesmos parâmetros mencionados e obteve como retorno do código, as representações gráficas do problema abordado, bem como o menor (Min) e maior (Max) valor da função objetivo, que pode ser chamada de Fitness, no contexto de algoritmos evolutivos. Além desse dado, obteve-se também o valor médio da função objetivo, o desvio padrão e o tempo para execução do código conforme o problema.

## III. RESULTADOS

### A. Descida de gradientes: unidimensional

A análise realizada levou em consideração a Equação 1. E foi determinado que o valor inicial para a variável,  $x$ , seria  $x_0 = 1$ , e a taxa de aprendizagem,  $\alpha$ ,  $\alpha = 0.1$ . Fez-se o cálculo da derivada para calcular a descida de gradientes

utilizando-se o método de diferenças finitas (MDF), adotando-se o passo,  $h = 0.01$ . Posteriormente, foi calculada a derivada analiticamente.

$$f(x) = x(x^2 - x - 1)e^{-x} \quad (1)$$

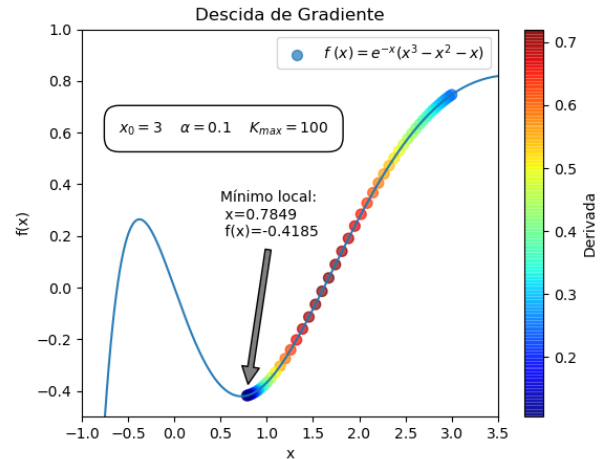
A Equação 1 também pode ser escrita como:

$$f(x) = (x^3 - x^2 - x)e^{-x} \quad (2)$$

| Derivada | MDF    | Analítica | $\bar{x}$ | $ \sigma $ |
|----------|--------|-----------|-----------|------------|
| $x_0$    | 1.0000 | 1.0000    | 1.0000    | 0.0000     |
| $x_1$    | 0.9627 | 0.9632    | 0.9630    | 0.0005     |

**Table I:** Comparação entre o próximo valor de  $x$ , tuilizando-se aproximação da derivada e calculando-a de forma analítica.

Nesta próxima etapa, foi utilizado o método de descida de gradientes, cuja derivadas foram obtidas analiticamente. O valor inicial definido foi de  $x_0 = 3$ , e taxa de aprendizagem,  $\alpha = 0.1$ . As condições de parada implementadas foram o tamanho da derivada,  $g_{min} = 0.1$  e o número máximo de iterações atingidos,  $k_{max} = 100$ .



**Figure 1:** Atualização do valor de  $x$ , atualizando-o com base no gradiente.

### B. Descida de gradientes: bidimensional

O objetivo abordado neste problema é utilizar o método de diferenças finitas, bem como o método analítico, para o

cálculo da derivada de uma função de duas variáveis. A função analisada é representada pela Equação 3.

$$f(x_1, x_2) = (4 - 2.1x_1^2 + \frac{x_1^3}{3})x_1^3 + x_1x_2 + (-4 + 4x_2^2)x_2^2 \quad (3)$$


$$f(x_1, x_2) = 4x_1^3 - 2.1x_1^5 + \frac{x_1^6}{3} + x_1x_2 - 4x_2^2 + 4x_2^4 \quad (4)$$

O gradiente das funções calculados analiticamente, por meio do algoritmo estão representados pela Equação 5.

$$\nabla f(x_1, x_2) = \begin{bmatrix} \frac{\partial f(x_1, x_2)}{\partial x_1} \\ \frac{\partial f(x_1, x_2)}{\partial x_2} \end{bmatrix} \quad (5)$$

$$\nabla f(x_1, x_2) = \begin{bmatrix} 2x_1^5 - 10.5x_1^4 + 12x_1^2 + x_2 \\ 16x_2^3 - 8x_2 + x_1 \end{bmatrix}$$

Executou-se o algoritmo elaborado para estimar mínimos da Equação 4, e foi implementado o método das diferenças finitas para duas variáveis, bem como o cálculo do gradiente de forma analítica. A Figura 2 representa a curva de nível da Equação 3.



**Figure 2:** Superfície representado no domínio  $-1 \leq x \leq 1$ .

### C. Aprendizagem de Máquinas

Este problema consistiu em realizar a busca de hiperparâmetros e *feature selection*. E o algoritmo para realizar a classificação foi o *k-nearest neighbors* (K-NN).

| Problema  | Min.    | Max.    | $\bar{x}$ | $\sigma$ | Tempo(s) |
|-----------|---------|---------|-----------|----------|----------|
| TSP       | 118.462 | 147.385 | 133.097   | 9.829    | 33.156   |
| Regressão | 1.814   | 2.175   | 1.907     | 0.135    | 253.481  |
| AM        | -0.816  | -0.810  | -0.814    | 0.002    | 380.070  |

**Table II:** Resultados Obtidos em 5 rodadas de teste.

### IV. DISCUSSION

Para o caso o Problema do Caxeiro Viajante, o algoritmo genético neste contexto, para os parâmetros adotados, não apresentou um resultado que se assemelhe ao ótimo. Fato que fica evidente ao observar a Figura 1 e 2, ao perceber que algumas rotas se cruzam. O valor da função objetivo converge muito rapidamente, ficando o valor, restrito a possíveis ótimos locais da função. É muito provável que ao rodar o algoritmo por um número maior de gerações, obtenha-se melhores resultados.

No problema de regressão, é possível perceber que foram obtidos resultados satisfatórios, com um erro quadrático que apresenta indícios de estar próximo do ótimo, tal como é observado nas Figuras 5, 6 e 7. Em todas as simulações, o valor da função objetivo converge.

O problema da busca de hiperparâmetros também apresenta uma boa convergência, para valores bem próximos. Indicando que a função objetivo está numa região de ótimo ou que está próxima a uma.

### REFERENCES

- [1] L. H. M. Costa, M. A. H. d. Castro, and H. Ramos, "Utilização de um algoritmo genético híbrido para operação ótima de sistemas de abastecimento de água," *Engenharia Sanitaria e Ambiental*, vol. 15, pp. 187–196, 2010.